파이썬 라이브러리를 활용한 데이터 분석

8장 데이터 준비하기: 조인, 병합, 변형

2020.07.02 2h

8.3 재형성과 피벗 p334

- **계층적 색인으로 재형성**
  - index와 columns 사이의 이동
  - Stack
    - **Index <= columns**
  - Unstack
    - **Index => columns**
- **긴 형식에서 넓은 형식으로**
  - Pivot
- **넓은 형식에서 긴 형식으로**
  - Melt

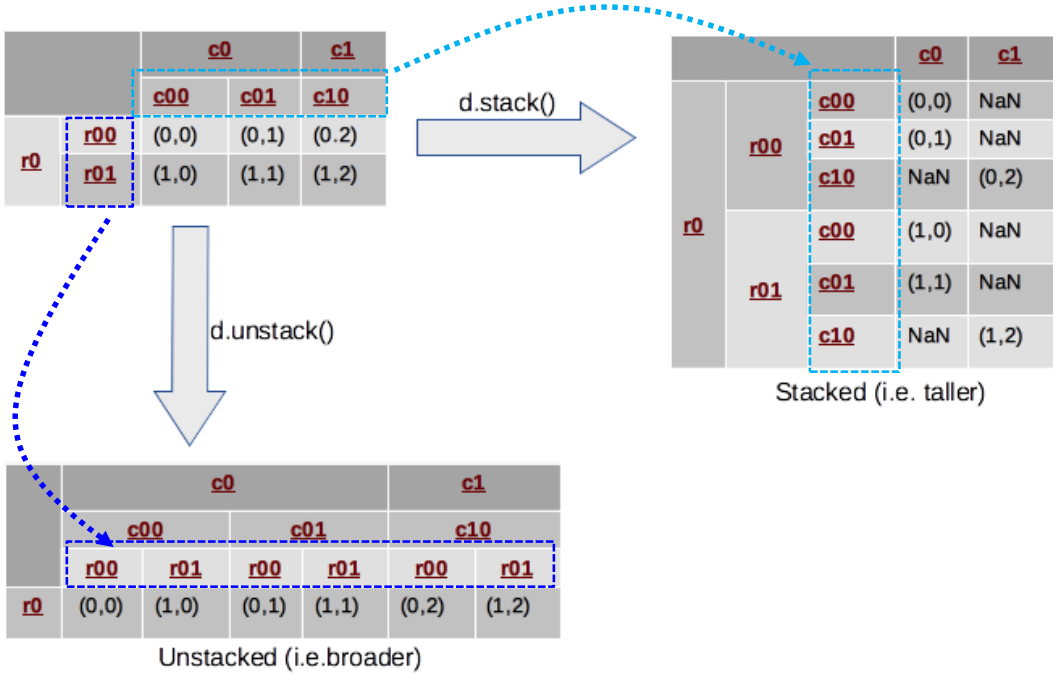

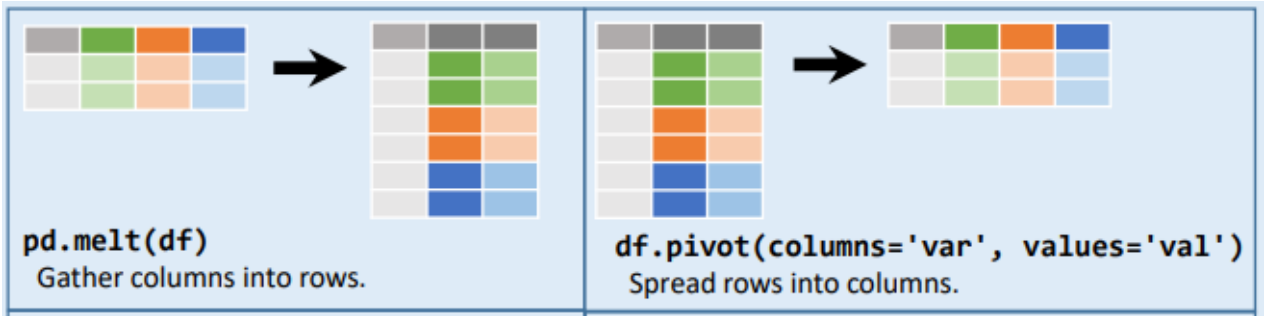

8장 데이터 준비하기: 조인, 병합, 변형

stack unstack

Stack과 unstack의 사전적 의미

- **stack을 영어사전에서 찾아보면 뜻**
  - stack[stæk]
    - **~ (sth) (up) (깔끔하게 정돈하여) 쌓다[포개다]; 쌓이다, 포개지다**
    - **~ sth (with sth) (어떤 곳에 물건을 쌓아서) 채우다**
- **Stack**
  - (위에서 아래로 길게, 높게) 쌓는 것이면
- **Unstack**
  - 옆으로 늘어 놓는 것(왼쪽에서 오른쪽으로 넓게)라고 생각

- **용어 정리**
  - Index == 인덱스 ==행 색인(인덱스)
  - Columns == 열 == 열 색인(인덱스)

출처: https://rfriend.tistory.com/276 [R, Python 분석과 프로그래밍의 친구 (by R Friend)]

stack과 unstack

- **열 인덱스를 행 인덱스로 바꾸거나 반대로 행 인덱스를 열 인덱스로 바꾸는 작업**
  - stack(): 데이터의 칼럼을 로우로 회전
    - **열 인덱스 -> 행 인덱스로 변환**
    - **열 인덱스가 반시계 방향으로 90도 회전한 것과 비슷한 모양**
  - unstack(): 로우를 칼럼으로 회전
    - **행 인덱스 -> 열 인덱스로 변환**
    - **마찬가지로 실행하면 행 인덱스가 반시계 방향으로 90도 회전한 것과 비슷**
  - 인덱스를 지정 방법
    - **문자열 이름과 순서를 표시하는 숫자 인덱스를 모두 사용 가능**

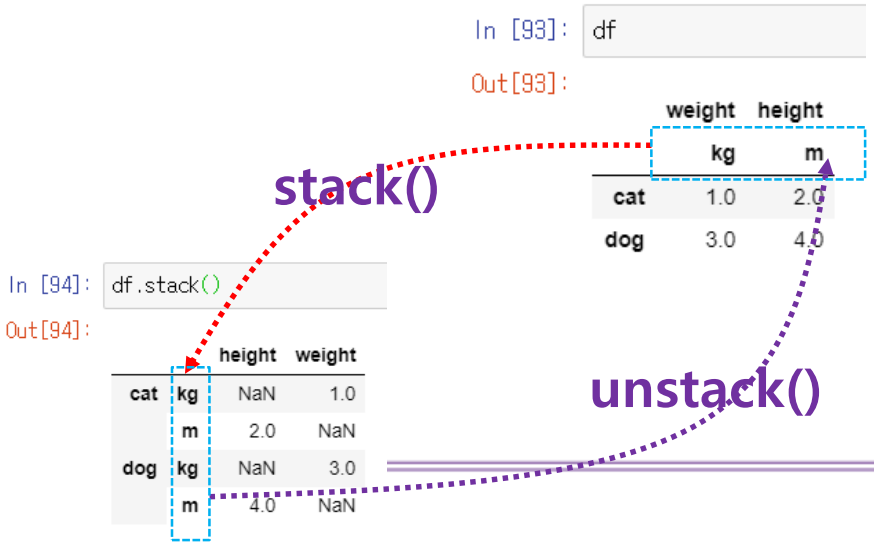

Reshaping by stacking

- **Stack: 열 레이블 => 행 인덱스로 이동**
  - stack: “pivot” a level of the (possibly hierarchical) column labels, returning a DataFrame with an index with a new inner-most level of row labels.
    - **(계층적) 열 레이블 수준을 "피벗“(회전)하여 가장 안쪽의 새로운 행 레이블의 인덱스 형태의 DataFrame을 반환**

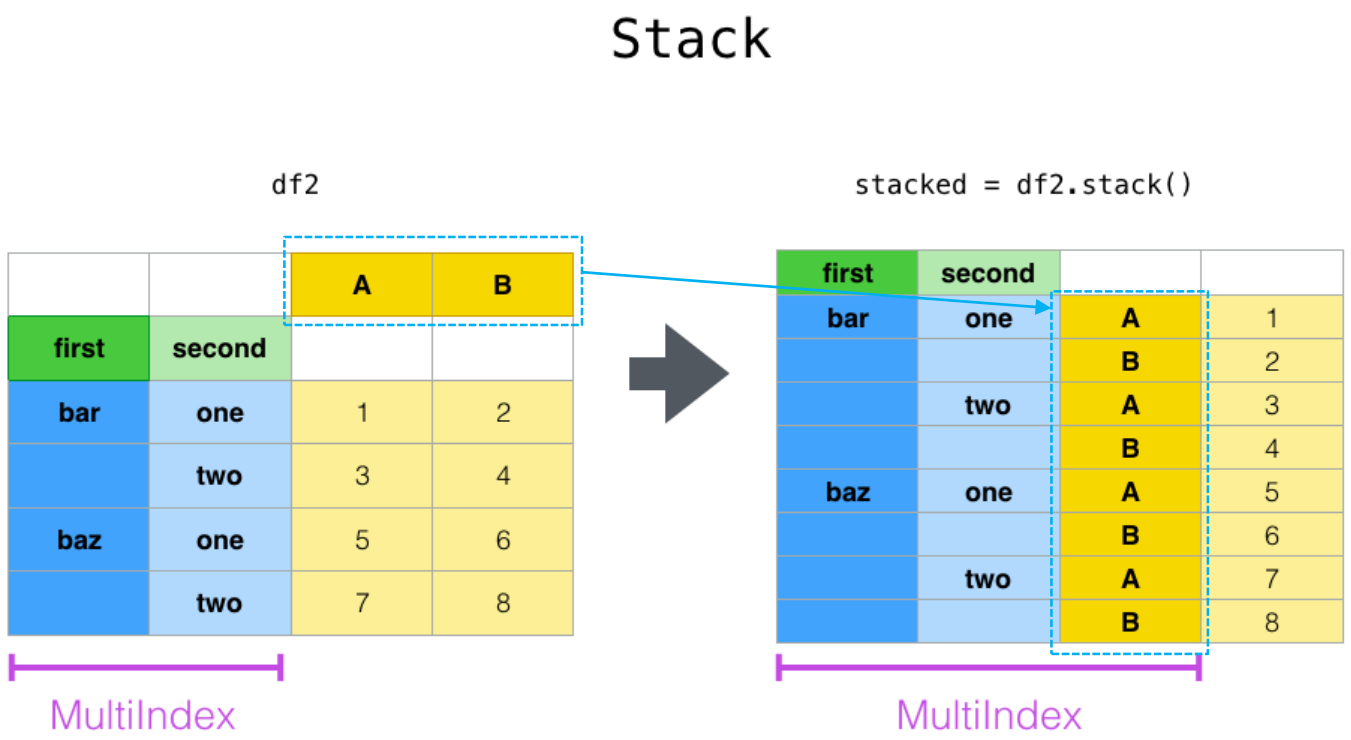

스택: 열 레이블 => 행의 인덱스로 이동

- **열의 레이블이 하나 줄어 행의 인덱스로 이동**
  - "rotates" or pivots from the columns in the data to the rows

```
In [120]: data = pd.DataFrame(np.arange(6).reshape((2, 3)),
   .....:                     index=pd.Index(['Ohio', 'Colorado'], name='state'),
   .....:                     columns=pd.Index(['one', 'two', 'three'],
   .....:                     name='number'))

In [121]: data
Out[121]:
number    one  two  three
state
Ohio        0    1      2
Colorado    3    4      5
```

Using the stack method on this data pivots the columns into the rows, producing a Series:

```
In [122]: result = data.stack()

In [123]: result
Out[123]:
state     number
Ohio      one       0
          two       1
          three     2
Colorado  one       3
          two       4
          three     5
dtype: int64
```

Reshaping by unstacking

- **Unstack: 행 인덱스 => 열 레이블로 이동**
  - unstack: (inverse operation of stack) "pivot" a level of the (possibly hierarchical) row index to the column axis, producing a reshaped DataFrame with a new inner-most level of column labels.
    - **unstack: (stack 역연산) (가급적 계층적) 행 인덱스의 레벨을 컬럼 축으로 "피벗"(회전)해 새로운 가장 안쪽 레벨의 컬럼 레이블로 재구성된 DataFrame을 반환**

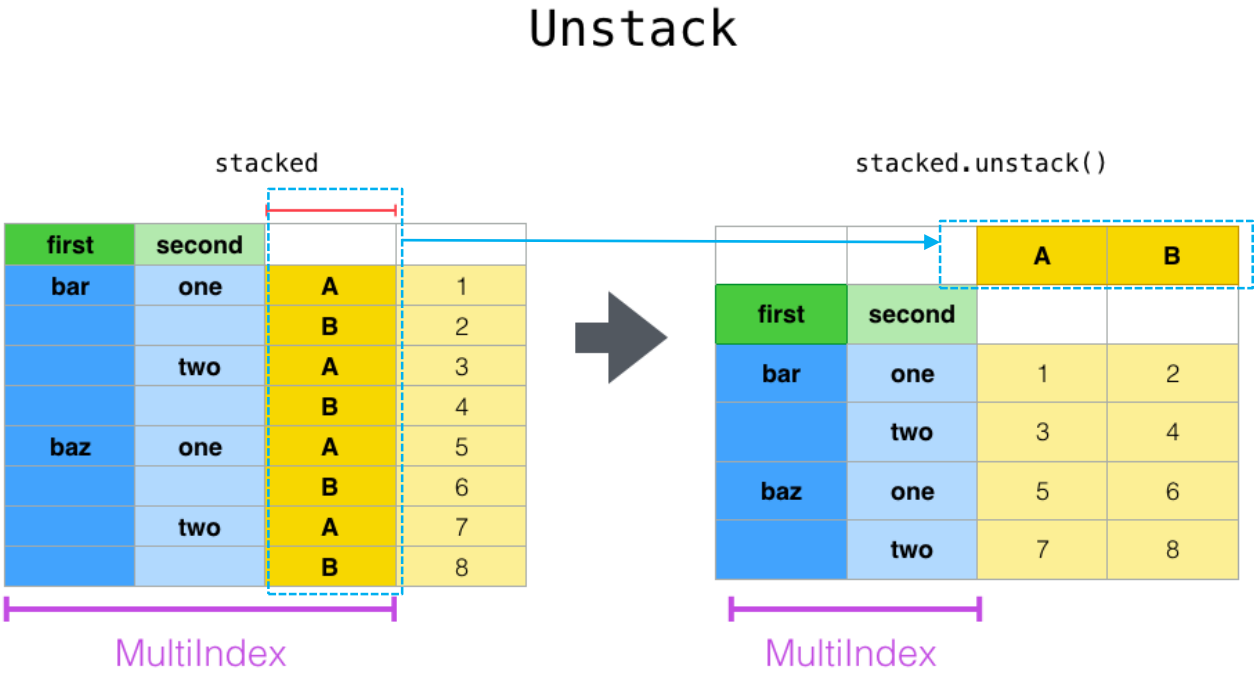

unstack(색인 첨자 번호)

- 다중 색인에서 첨자로 색인을 지정

Unstack(0)

stacked

first	second		
bar	one	A	1
		B	2
	two	A	3
		B	4
baz	one	A	5
		B	6
	two	A	7
		B	8

MultiIndex

0 1 2

stacked.unstack(0)
or
stacked.unstack('first')

	first	bar	baz
second			
one	A	1	5
	B	2	6
two	A	3	7
	B	4	8

MultiIndex

Unstack(1)

stacked

first	second		
bar	one	A	1
		B	2
	two	A	3
		B	4
baz	one	A	5
		B	6
	two	A	7
		B	8

MultiIndex

stacked.unstack(1)
or
stacked.unstack('second')

	second	one	two
first			
bar	A	1	3
	B	2	4
baz	A	5	7
	B	6	8

MultiIndex

Unstack p336

- **계층적 색인의 시리즈에서 다시 DataFrame을 반환(가로로 넓어짐)**
  - 가장 안쪽부터(가장 큰 첨자 숫자) 열로 지정

```
In [123]: result
Out[123]:
state     number
Ohio      one      0
          two      1
          three    2
Colorado  one      3
          two      4
          three    5
dtype: int64
```

```
In [124]: result.unstack()
Out[124]:
number    one  two  three
state
Ohio        0    1      2
Colorado    3    4      5
```

  - 레벨 숫자나 이름으로 단계를 지정 가능

0 1

```
In [125]: result.unstack(0)
Out[125]:
state   Ohio  Colorado
number
one        0         3
two        1         4
three      2         5

In [126]: result.unstack('state')
Out[126]:
state   Ohio  Colorado
number
one        0         3
two        1         4
three      2         5
```

Unstack, stack

- **Unstack: 지정한 인덱스 state를 열로 지정**

```
In [135]: df = pd.DataFrame({'left': result, 'right': result + 5},
   .....:                   columns=pd.Index(['left', 'right'], name='side'))

In [136]: df
Out[136]:
side             left  right
state    number
Ohio     one        0      5
         two        1      6
         three      2      7
Colorado one        3      8
         two        4      9
         three      5     10
```

0 1

```
In [137]: df.unstack('state')
Out[137]:
side   left          right
state  Ohio Colorado  Ohio Colorado
number
one       0        3     5        8
two       1        4     6        9
three     2        5     7       10
```

0 1

```
In [138]: df.unstack('state').stack('side')
Out[138]:
state           Colorado  Ohio
number side
one    left            3     0
       right           8     5
two    left            4     1
       right           9     6
three  left            5     2
       right          10     7
```

- **stack: 지정한 열 side를 인덱스로**

색인과 칼럼이 모두 계층적 색인

- **행과 열이 모두 2층인 계층적 색인**

In [8]:

```
np.random.seed(0)
df4 = pd.DataFrame(np.round(np.random.randn(6, 4), 2),
                   columns=[["A", "A", "B", "B"],
                            ["C", "D", "C", "D"]],
                   index=[["M", "M", "M", "F", "F", "F"],
                          ["id_" + str(i + 1) for i in range(3)] * 2])
df4.columns.names = ["Cidx1", "Cidx2"]
df4.index.names = ["Ridx1", "Ridx2"]
df4
```

	Cidx1	A		B	
	Cidx2	C	D	C	D
Ridx1	Ridx2				
M	id_1	1.76	0.40	0.98	2.24
	id_2	1.87	-0.98	0.95	-0.15
	id_3	-0.10	0.41	0.14	1.45
F	id_1	0.76	0.12	0.44	0.33
	id_2	1.49	-0.21	0.31	-0.85
	id_3	-2.55	0.65	0.86	-0.74

DataFrame.stack('열이름')

- 열 => 색인으로

	Cidx1	A		B	
	Cidx2	C	D	C	D
Ridx1	Ridx2				
M	id_1	1.76	0.40	0.98	2.24
	id_2	1.87	-0.98	0.95	-0.15
	id_3	-0.10	0.41	0.14	1.45
F	id_1	0.76	0.12	0.44	0.33
	id_2	1.49	-0.21	0.31	-0.85
	id_3	-2.55	0.65	0.86	-0.74

```
In [9]:
```

```
df4.stack("Cidx1")
```

		Cidx2	C	D
Ridx1	Ridx2	Cidx1		
M	id_1	A	1.76	0.40
		B	0.98	2.24
	id_2	A	1.87	-0.98
		B	0.95	-0.15
	id_3	A	-0.10	0.41
		B	0.14	1.45
F	id_1	A	0.76	0.12
		B	0.44	0.33
	id_2	A	1.49	-0.21
		B	0.31	-0.85
	id_3	A	-2.55	0.65
		B	0.86	-0.74

DataFrame.stack(열첨자)

- 열 => 색인으로

	Cidx1	A		B	
	Cidx2	C	D	C	D
Ridx1	Ridx2				
M	id_1	1.76	0.40	0.98	2.24
	id_2	1.87	-0.98	0.95	-0.15
	id_3	-0.10	0.41	0.14	1.45
F	id_1	0.76	0.12	0.44	0.33
	id_2	1.49	-0.21	0.31	-0.85
	id_3	-2.55	0.65	0.86	-0.74

```
In [10]:
```

```
df4.stack(1)
```

		Cidx1	A	B
Ridx1	Ridx2	Cidx2		
M	id_1	C	1.76	0.98
		D	0.40	2.24
	id_2	C	1.87	0.95
		D	-0.98	-0.15
	id_3	C	-0.10	0.14
		D	0.41	1.45
F	id_1	C	0.76	0.44
		D	0.12	0.33
	id_2	C	1.49	0.31
		D	-0.21	-0.85
	id_3	C	-2.55	0.86
		D	0.65	-0.74

DataFrame.unstack('색인이름')

- 색인 => 열로

```
In [11]:
df4.unstack("Ridx2")
```

Cidx1	A						B					
Cidx2	C			D			C			D		
Ridx2	id_1	id_2	id_3	id_1	id_2	id_3	id_1	id_2	id_3	id_1	id_2	id_3
Ridx1												
F	0.76	1.49	-2.55	0.12	-0.21	0.65	0.44	0.31	0.86	0.33	-0.85	-0.74
M	1.76	1.87	-0.10	0.40	-0.98	0.41	0.98	0.95	0.14	2.24	-0.15	1.45

	Cidx1	A		B	
	Cidx2	C	D	C	D
Ridx1	Ridx2				
M	id_1	1.76	0.40	0.98	2.24
	id_2	1.87	-0.98	0.95	-0.15
	id_3	-0.10	0.41	0.14	1.45
F	id_1	0.76	0.12	0.44	0.33
	id_2	1.49	-0.21	0.31	-0.85
	id_3	-2.55	0.65	0.86	-0.74

DataFrame.unstack(열첨자)

- 색인 => 열로

```
In [12]:
    df4.unstack(0)
```

	Cidx1	A		B	
	Cidx2	C	D	C	D
Ridx1	Ridx2				
M	id_1	1.76	0.40	0.98	2.24
	id_2	1.87	-0.98	0.95	-0.15
	id_3	-0.10	0.41	0.14	1.45
F	id_1	0.76	0.12	0.44	0.33
	id_2	1.49	-0.21	0.31	-0.85
	id_3	-2.55	0.65	0.86	-0.74

Cidx1	A				B			
Cidx2	C		D		C		D	
Ridx1	F	M	F	M	F	M	F	M
Ridx2								
id_1	0.76	1.76	0.12	0.40	0.44	0.98	0.33	2.24
id_2	1.49	1.87	-0.21	-0.98	0.31	0.95	-0.85	-0.15
id_3	-2.55	-0.10	0.65	0.41	0.86	0.14	-0.74	1.45

요약 정리 stack unstack

Stack / Unstack

```
>>> stacked = df5.stack()
>>> stacked.unstack()
```

Pivot a level of column labels
Pivot a level of index labels

		0	1
1	5	0.233482	0.390959
2	4	0.184713	0.237102
3	3	0.433522	0.429401

Unstacked

1	5	0	0.233482
		1	0.390959
2	4	0	0.184713
		1	0.237102
3	3	0	0.433522
		1	0.429401

Stacked

데이터 재구조화 (Reshaping data by stack, unstack)

pd.DataFrame.stack() , pd.DataFrame.unstack()

Stacked (long)

index		
1	Col_1	10
1	Col_1	20
2	Col_2	30
2	Col_2	40

unstack / *stack*

Un-stacked (wide)

index	Col_1	Col_2
1	10	30
2	20	40

8장 데이터 준비하기: 조인, 병합, 변형

Pivot Melt

피봇 개요

- **피봇 테이블(pivot table)**
  - 데이터 열 중에서 두 개의 열을 각각 행 인덱스, 열 인덱스로 사용
    - **맞는 데이터를 저장하여 펼쳐놓은 것**
- **df1.pivot(index, columns, values)**
  - index, columns: 각각 인덱스, 열 인덱스로 사용할 이름
  - values: 데이터로 사용할 열 이름을 지정
    - **행 인덱스의 라벨 값이 첫번째 키의 값과 같고 열 인덱스의 라벨 값이 두번째 키의 값과 같은 데이터를 찾아서 해당 칸에 저장**
    - **만약 주어진 데이터가 존재하지 않으면 해당 칸에 NaN 값 저장**

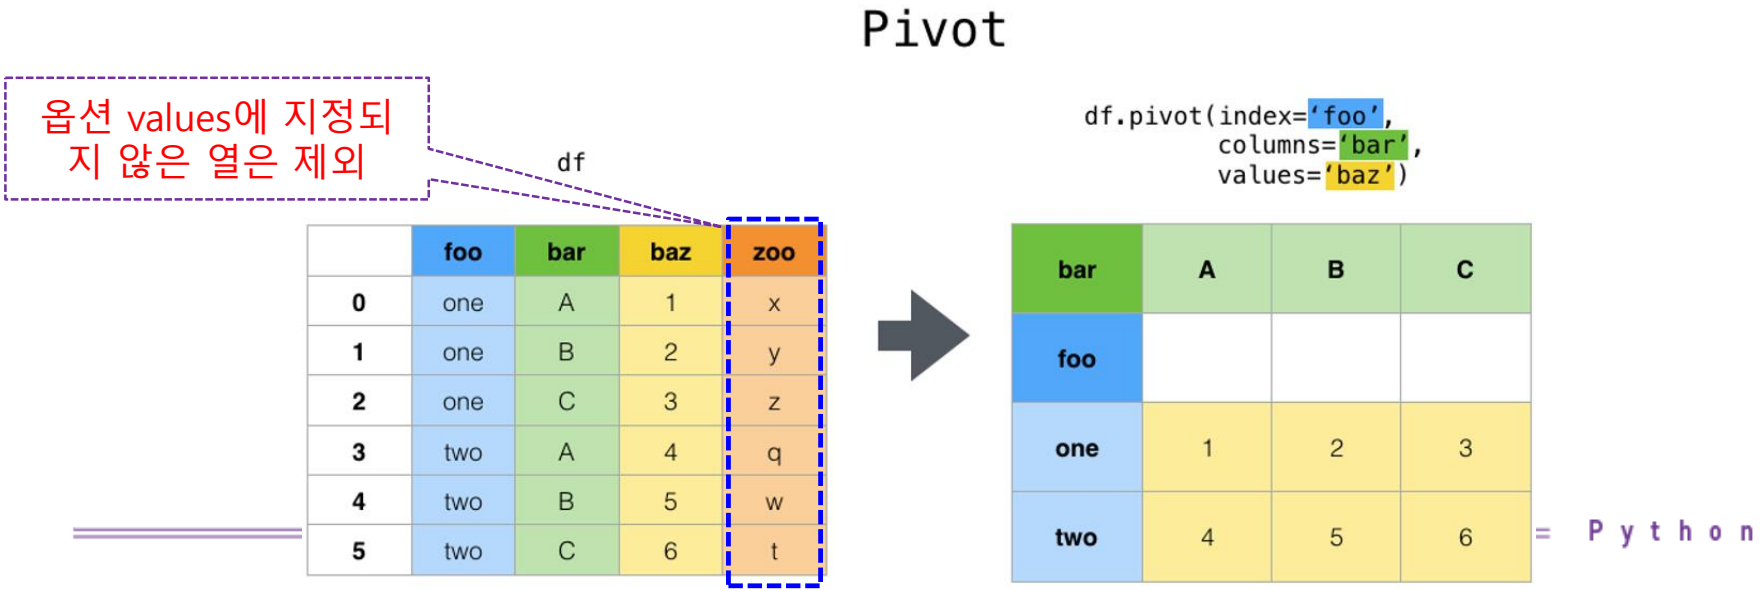

	foo	bar	baz	zoo
0	one	A	1	x
1	one	B	2	y
2	one	C	3	z
3	two	A	4	q
4	two	B	5	w
5	two	C	6	t

bar	A	B	C
foo			
one	1	2	3
two	4	5	6

3개의 인자

- **index='cust_id', columns='prod_cd', values**

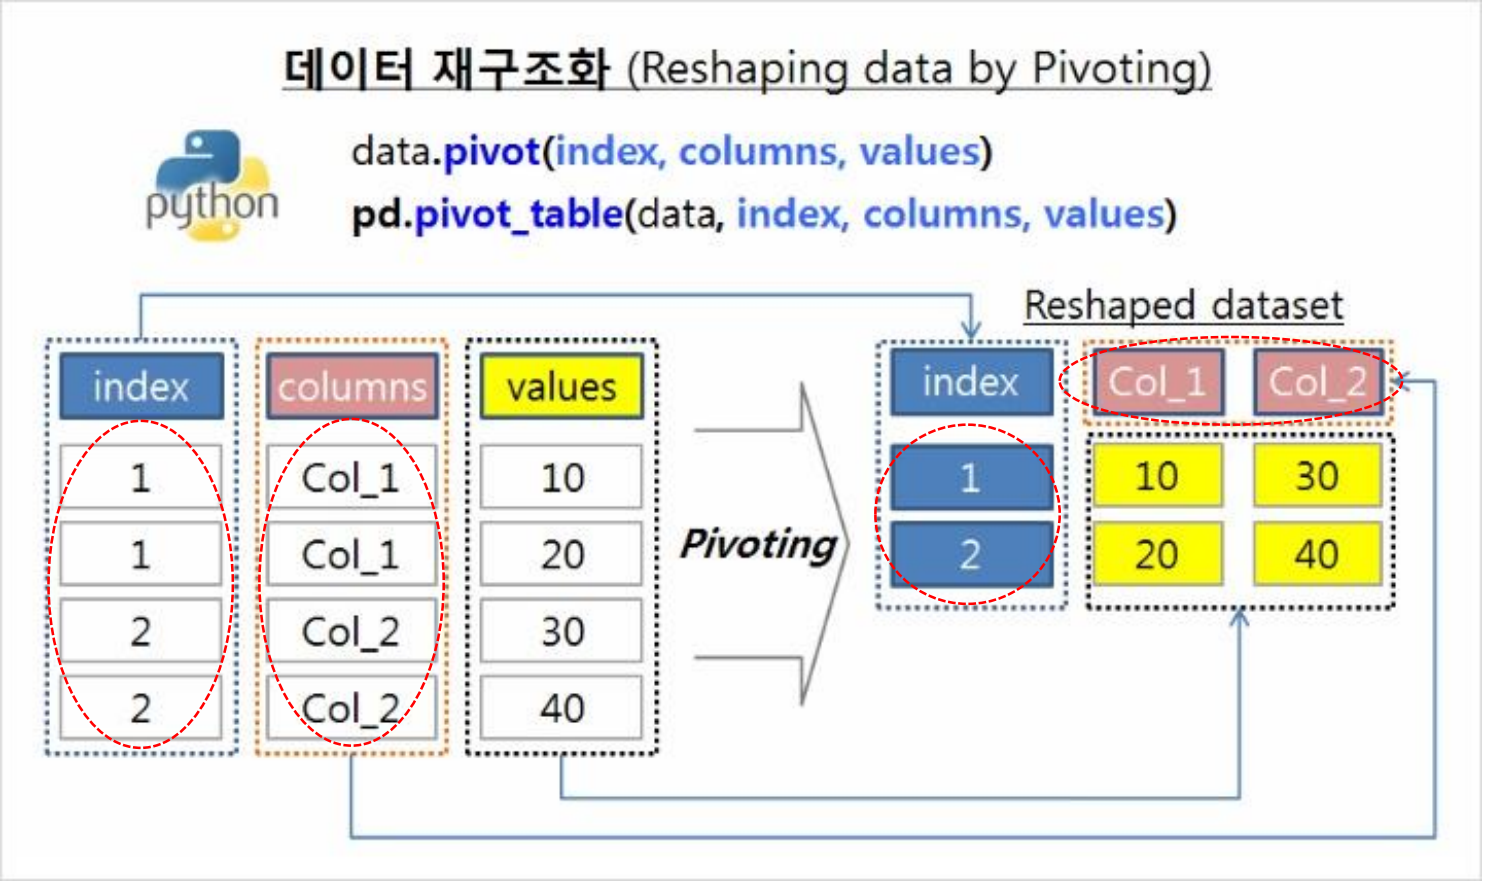

Pivot 옵션

- **옵션 index**
  - 인덱스 지정
    - **지정하지 않으면 원래 인덱스 사용**
- **옵션 columns**
  - 열로 지정
- **옵션 values**
  - 값 지정
    - **지정하지 않으면 남아 있는 모든 열이 다중 색인으로 열 이름이 들어 감**
- **옵션에 없는 열**
  - 지역은 제거

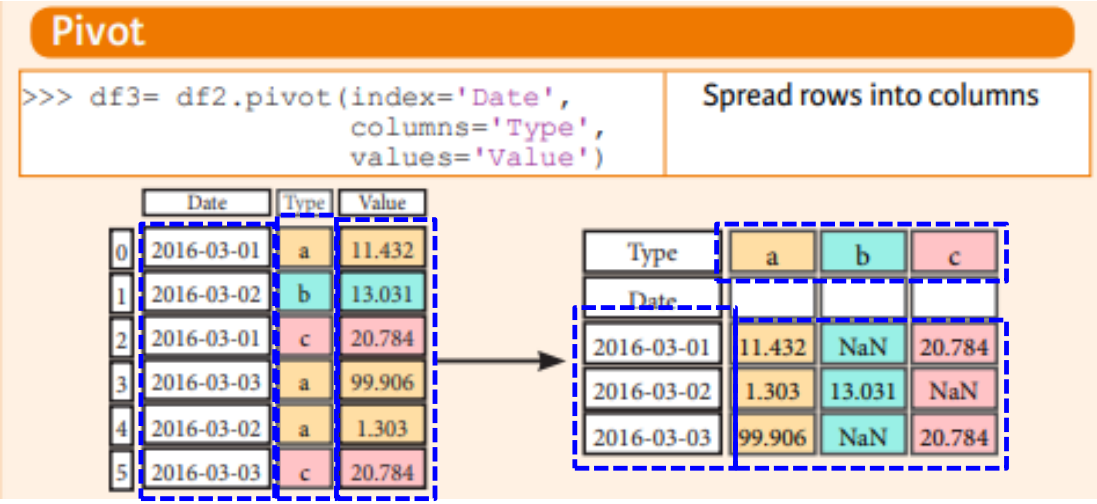

	도시	연도	인구	지역
0	서울	2015	9904312	수도권
1	서울	2010	9631482	수도권
2	서울	2005	9762546	수도권
3	부산	2015	3448737	경상권
4	부산	2010	3393191	경상권
5	부산	2005	3512547	경상권
6	인천	2015	2890451	수도권
7	인천	2010	263203	수도권

```
df1.pivot("도시", "연도", "인구")
```

연도	2005	2010	2015
도시			
부산	3512547.0	3393191.0	3448737.0
서울	9762546.0	9631482.0	9904312.0
인천	NaN	263203.0	2890451.0

pivot == set_index().unstack()

- **피봇테이블**
  - set_index 명령과 unstack 명령을 사용해서 생성도 가능
    - **df.pivot(index, columns, values)**
    - **df.set_index([index, columns])[values].unstack())**
  - set_index()
    - **지정한 열을 행 인텍스로 지정**

	도시	연도	인구	지역
0	서울	2015	9904312	수도권
1	서울	2010	9631482	수도권
2	서울	2005	9762546	수도권
3	부산	2015	3448737	경상권
4	부산	2010	3393191	경상권
5	부산	2005	3512547	경상권
6	인천	2015	2890451	수도권
7	인천	2010	263203	수도권

```
df1.pivot("도시", "연도", "인구")
```

연도	2005	2010	2015
도시			
부산	3512547.0	3393191.0	3448737.0
서울	9762546.0	9631482.0	9904312.0
인천	NaN	263203.0	2890451.0

```
df1.set_index(["도시", "연도"])['인구'].unstack()
```

	인구		
연도	2005	2010	2015
도시			
부산	3512547.0	3393191.0	3448737.0
서울	9762546.0	9631482.0	9904312.0
인천	NaN	263203.0	2890451.0

8장 데이터 준비하기: 조인, 병합, 변형

Melt Pivot

녹이는 **melt()** 개요

- **데이터프레임의 컬럼 이름 자체를 한 컬럼 varibale에 모두 내리고 해당하는 값을 다른 칼럼 value에 따로 빼는 것**
  - 변수 id_vars를 기준으로 원래 데이터프레임에 있던 여러 개의 칼럼 이름을 'variable' 칼럼에 위에서 아래로 길게 쌓아놓고, 'value' 칼럼에 id_vars와 variable에 해당하는 값을 넣어주는 식으로 데이터를 다시 생성
    - **기존 index는 상관 없이 반환 값의 인덱스는 기본 정수 인덱스 RangeIndex**

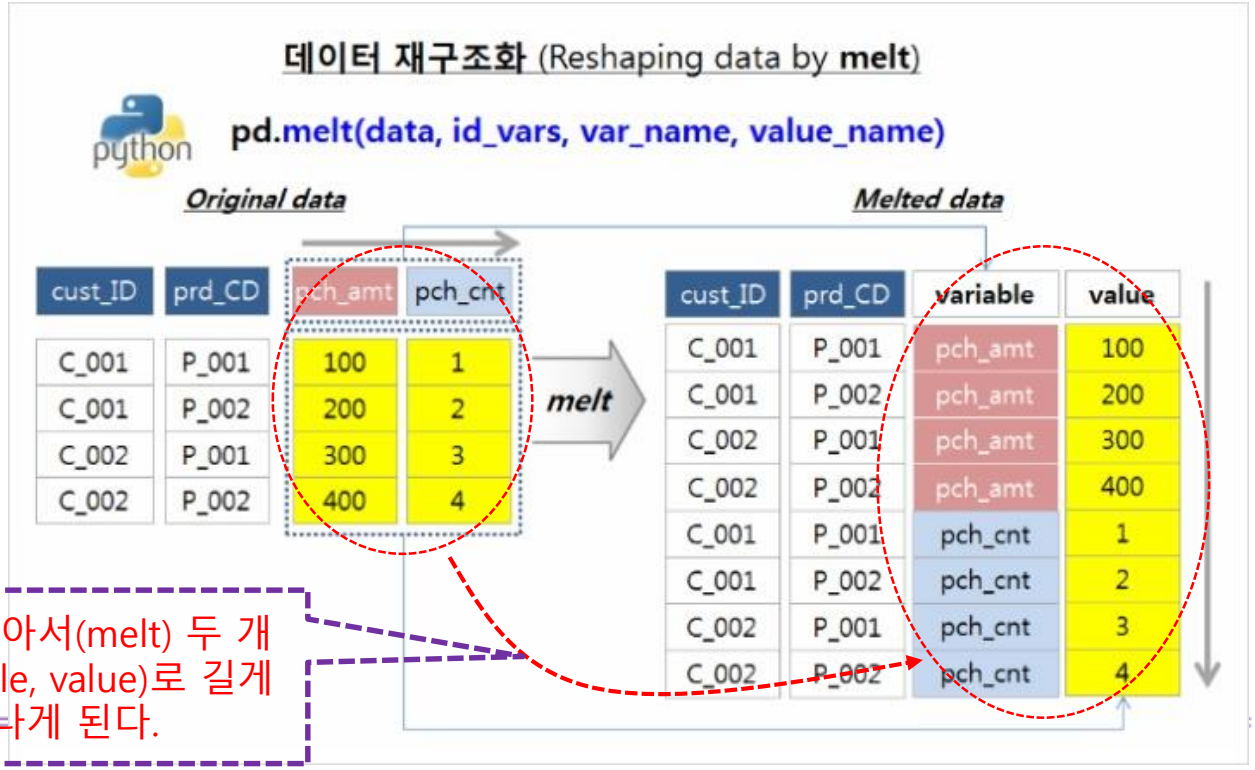

메소드 melt 인자

- DataFrame.melt(self, id_vars=None, value_vars=None, var_name=None, value_name='value', col_level=None)
  - DataFrame를 와이드 형식에서 긴 형식으로 unpivot: 모양이 길어짐
    - 선택적으로 식별자 집합(identifiers set)을 남김
      - 열을 그대로 유지하는 칼럼
      - Unpivot a DataFrame from wide to long format, optionally leaving identifiers set.
    - 식별자 변수(id_vars)에 지정된 여러 열을 유지하는 형태의 DataFrame으로 변환
      - 기본적으로 식별자 변수 id_vars 외의 모든 열은 두 개의 열인 'variable'과 'value ' 로 " unpivoluted " 됨
      - 옵션으로 value_vars에 지정된 열만도 가능
    - 단 두 개의 열(non-identifier columns)인 'variable'과 'value'만 남음
      - 이 두 열의 이름은 각각 var_name, value_name으로 수정 가능

    - This function is useful to massage a DataFrame into a format where one or more columns are identifier variables (id_vars), while all other columns, considered measured variables (value_vars), are "unpivoted" to the row axis, leaving just two non-identifier columns, 'variable' and 'value'.

두 개의 열로, 세로로 길게: melt()

- **여러 칼럼을 두 개 열 varibale과 value로 병합하고 긴 형태로 재구성**
  - 인자가 없으면 모든 열을 varibale과 value로 구성
  - 인자 id_vars
  - 인자 value_vars
  - 안저 var_name, value_name

```
In [7]: mydf.melt(id_vars='이름', value_vars='영어')
```

Out[7]:

	이름	variable	value
0	홍길동	영어	99
1	임걱정	영어	79
2	아무개	영어	55

```
In [9]: mydf.melt(id_vars='이름', value_vars='영어',
                  var_name='과목', value_name='점수')
```

Out[9]:

	이름	과목	점수
0	홍길동	영어	99
1	임걱정	영어	79
2	아무개	영어	55

```
In [3]: mydf = pd.DataFrame({'이름': ['홍길동', '임걱정', '아무개'],
                             '영어': [99, 79, 55],
                             '수학': [92, 82, 72]})
        mydf
```

Out[3]:

	이름	영어	수학
0	홍길동	99	92
1	임걱정	79	82
2	아무개	55	72

```
In [5]: mydf.melt()
```

Out[5]:

	variable	value
0	이름	홍길동
1	이름	임걱정
2	이름	아무개
3	영어	99
4	영어	79
5	영어	55
6	수학	92
7	수학	82
8	수학	72

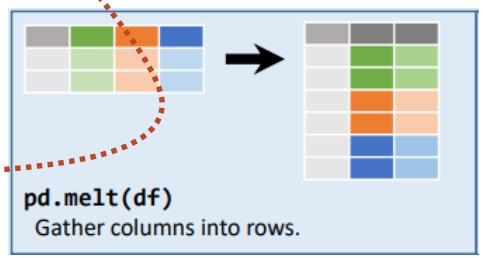


```
In [6]: mydf.melt(id_vars='이름')
```

Out[6]:

	이름	variable	value
0	홍길동	영어	99
1	임걱정	영어	79
2	아무개	영어	55
3	홍길동	수학	92
4	임걱정	수학	82
5	아무개	수학	72

함수 melt 인자 활용

- 넓은 형식에서 긴 형식으로
  - 주요 인자
    - id_vars: 하나 이상의 열을 식별자 집합으로 지정
    - value_vars: 열 variable과 value에 사용할 열 들을 지정
      - 없으면 id_vars 외의 다른 열은 모두 variable과 value로 지정
- 결과
  - id_vars와 'variable'와 'value' 열만 남음
    - 'variable'은 열 이름이 저장
      - variable 열 이름은 var_name으로 수정 가능
    - 'value' 에는 실제 값이 저장
      - value 열 이름은 value_name으로 수정 가능

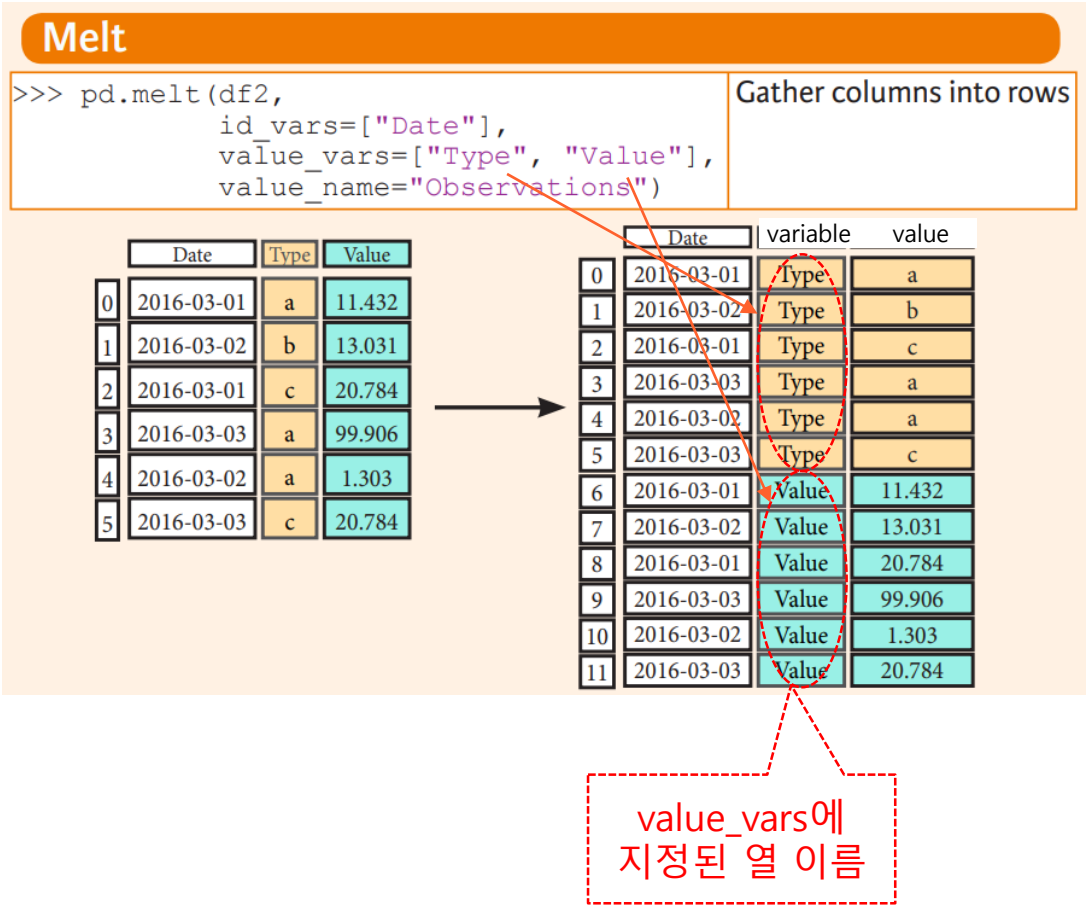

칼럼 이름 수정 인자

- **함수**
  - pd.melt(
  - frame: pandas.core.frame.DataFrame,
  - id_vars=None,
  - value_vars=None,
  - var_name=None,
  - value_name='value',
  - col_level=None,
  -)

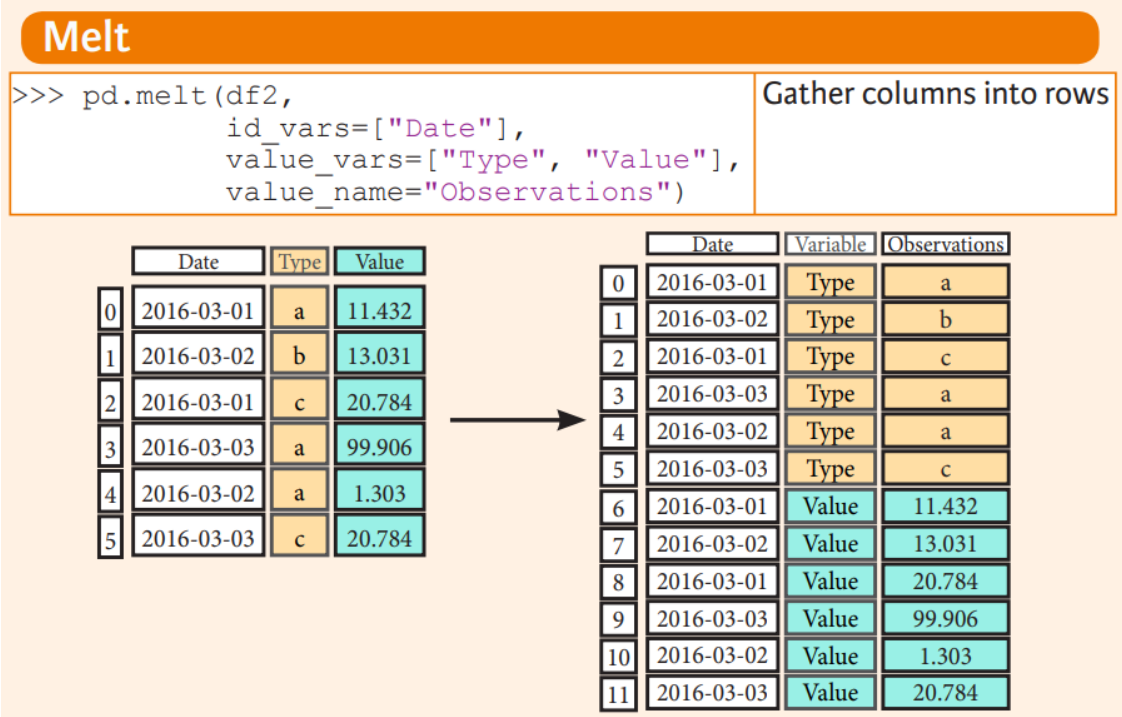

- **variable열은 var_name으로 수정 가능**
- **value열은 value_name으로 수정 가능**

구분자 인자: id_vars

- **id_vars = ['key']**
  - id_vars를 식별자 집합으로 사용
  - 다른 2개의 열을 열 variable과 value에 저장
    - **열 이름과 값으로 지정해 사용**

```
In [157]: df = pd.DataFrame({'key': ['foo', 'bar', 'baz'],
   .....:                    'A': [1, 2, 3],
   .....:                    'B': [4, 5, 6],
   .....:                    'C': [7, 8, 9]})

In [158]: df
Out[158]:
   A  B  C  key
0  1  4  7  foo
1  2  5  8  bar
2  3  6  9  baz
```

The 'key' column may be a group indicator, and the other columns are data values. When using `pandas.melt`, we must indicate which columns (if any) are group indicators. Let's use 'key' as the only group indicator here:

```
In [159]: melted = pd.melt(df, ['key'])

In [160]: melted
Out[160]:
   key variable  value
0  foo        A      1
1  bar        A      2
2  baz        A      3
3  foo        B      4
4  bar        B      5
5  baz        B      6
6  foo        C      7
7  bar        C      8
8  baz        C      9
```

인자 value_vars

- **value_vars: tuple, list, or ndarray, optional**
  - 데이터 값으로 사용할 칼럼을 지정
    - **열 variable에 값으로 사용되는 column 이름**
      - **Column(s) to unpivot. If not specified, uses all columns that are not set as id_vars**

```
>>> df = pd.DataFrame({'A': {0: 'a', 1: 'b', 2: 'c'},
...                    'B': {0: 1, 1: 3, 2: 5},
...                    'C': {0: 2, 1: 4, 2: 6}})
>>> df
   A  B  C
0  a  1  2
1  b  3  4
2  c  5  6
```

```
>>> pd.melt(df, id_vars=['A'], value_vars=['B'])
   A variable  value
0  a        B      1
1  b        B      3
2  c        B      5
```

```
>>> pd.melt(df, id_vars=['A'], value_vars=['B', 'C'])
   A variable  value
0  a        B      1
1  b        B      3
2  c        B      5
3  a        C      2
4  b        C      4
5  c        C      6
```

In [102]:
```
df
```

Out[102]:

	key	A	B	C
0	foo	1	4	7
1	bar	2	5	8
2	baz	3	6	9

In [101]:
```
pd.melt(df, id_vars=['key'], value_vars=['A', 'B'])
```

Out[101]:

	key	variable	value
0	foo	A	1
1	bar	A	2
2	baz	A	3
3	foo	B	4
4	bar	B	5
5	baz	B	6

식별자 변수 없이도 가능

- **인자 id_vars 없이**
  - 열 variable, value만 보임

```
In [283]: df = pd.DataFrame({'key': ['foo', 'bar', 'baz'],
                             'A': [1, 2, 3],
                             'B': [4, 5, 6],
                             'C': [7, 8, 9]})
          df
```

Out[283]:

	key	A	B	C
0	foo	1	4	7
1	bar	2	5	8
2	baz	3	6	9

```
In [106]: pd.melt(df, value_vars=['A', 'B', 'C'])
```

Out[106]:

	variable	value
0	A	1
1	A	2
2	A	3
3	B	4
4	B	5
5	B	6
6	C	7
7	C	8
8	C	9

```
In [107]: pd.melt(df, value_vars=['key', 'A', 'B'])
```

Out[107]:

	variable	value
0	key	foo
1	key	bar
2	key	baz
3	A	1
4	A	2
5	A	3
6	B	4
7	B	5
8	B	6

피벗으로 원래의 형식으로 복원

- **원 df를 녹인 후**
  - 다시 피봇하여
    - **reset_index()**
      - **원 df**

In [292]:
```
df = pd.DataFrame({'key': ['foo', 'bar', 'baz'],
                   'A': [1, 2, 3],
                   'B': [4, 5, 6],
                   'C': [7, 8, 9]})
df
```

Out[292]:

	key	A	B	C
0	foo	1	4	7
1	bar	2	5	8
2	baz	3	6	9

In [285]:
```
pd.melt?
```

In [293]:
```
melted = pd.melt(df, ['key'])
melted
```

Out[293]:

	key	variable	value
0	foo	A	1
1	bar	A	2
2	baz	A	3
3	foo	B	4
4	bar	B	5
5	baz	B	6
6	foo	C	7
7	bar	C	8
8	baz	C	9

index columns value

In [294]:
```
reshaped = melted.pivot('key', 'variable', 'value')
reshaped
```

Out[294]:

variable	A	B	C
key			
bar	2	5	8
baz	3	6	9
foo	1	4	7

In [295]:
```
reshaped.reset_index()
```

Out[295]:

variable	key	A	B	C
0	bar	2	5	8
1	baz	3	6	9
2	foo	1	4	7